

PLAN DE TESIS

1. TITULO

“DETERMINACIÓN DE UN MODELO MATEMÁTICO ESPECÍFICO PARA LA PREDICCIÓN DE LA FRAGMENTACIÓN DE ROCA MEDIANTE MACHINE LEARNING EN UNA MINA EN EL SUR”

2. ANTECEDENTES REFERENCIALES

A continuación, se describen los antecedentes relacionados al tema de investigación, realizados en el ámbito internacional, nacional y local.

2.1. ANTECEDENTES INTERNACIONALES

- Sui Y., et al. (2025) en su estudio "Open-Pit Bench Blasting Fragmentation Prediction Based on Stacking Integrated Strategy" analizan la predicción de la fragmentación mediante inteligencia artificial para mejorar la precisión en proyectos mineros. Emplearon un dataset de 97 muestras y un modelo de ensamble tipo Stacking que combina los algoritmos Random Forest y XGBoost. Los resultados mostraron una alta precisión con un coeficiente R^2 de 0.943 y un error RMSE de 0.04435. Identificaron que el módulo de elasticidad (E), la relación taco/burden (T/B) y el tamaño de bloque in-situ (X_B) son las variables que más influyen en el resultado. El estudio concluye que la integración de modelos supera la precisión de los métodos individuales, siendo una herramienta eficaz para optimizar voladuras.
- Ohadi B., et al. (2019) en su estudio "Predicting blast-induced outcomes using random forest models of multi-year blasting data from an open pit mine" analizan la predicción de la fragmentación y el movimiento de roca mediante el uso de parámetros de diseño y características geomecánicas. A través del análisis de 451 eventos de voladura recolectados durante varios años en una mina de Canadá y el empleo de algoritmos de Bosques Aleatorios (Random Forest) y Árboles de Decisión, los autores identifican que la calidad de la roca (RQD) y su resistencia a la compresión son las variables con mayor peso estadístico en los resultados

finales. El estudio concluye que el uso de analítica de datos permite generar modelos predictivos precisos que sirven como guía operativa para optimizar los diseños de voladura basándose en las condiciones reales del macizo rocoso.

- Chandrahas N., et al. (2022) en su investigación "XG Boost Algorithm to Simultaneous Prediction of Rock Fragmentation and Induced Ground Vibration Using Unique Blast Data" proponen el uso del algoritmo XGBoost para predecir simultáneamente la fragmentación y la vibración del terreno. El estudio utilizó una base de datos de voladura y comparó el desempeño de XGBoost frente a modelos de redes neuronales y regresiones multilíneas. Los resultados demostraron que XGBoost obtuvo una mayor precisión con un coeficiente R^2 de 0.92 para la fragmentación, superando a los métodos convencionales. El estudio concluye que este algoritmo es altamente eficiente para manejar la complejidad de las variables de voladura, permitiendo optimizar los resultados operativos de forma más rápida y confiable que los modelos tradicionales.

2.2. ANTECEDENTES NACIONALES

- Ramírez R., et al. (2025) en su trabajo "Predicción de Fragmentación de Roca mediante Machine Learning en Voladuras de Minería a Tajo Abierto" presentan la implementación de un modelo predictivo en una mina de cobre en Perú. El modelo fue entrenado con más de 200 eventos de voladura utilizando variables geológicas, de perforación y diseño de malla a través de la plataforma DataFrag. Los resultados mostraron una precisión del 85% en la predicción del P_{80} , superando el 55% obtenido con el modelo tradicional de Kuz-Ram, y reportaron un error absoluto medio (MAE) de 4.35. El estudio concluye que el uso de analítica avanzada y aprendizaje automático permite anticiparse a las necesidades operativas, optimizando el proceso de conminución y mejorando la productividad en la minería 4.0.

- Vargas N. y Marcelo M. (2024) en su tesis titulada "Optimización de la voladura en una mina superficial a través de un modelo predictivo para determinar el nivel de fragmentación aplicando Machine Learning" evalúan el uso del aprendizaje automático supervisado para optimizar los resultados de fragmentación. Emplearon una metodología cuantitativa basada en modelos lineales generalizados (GLM), específicamente regresiones Gamma y Beta, analizando una base de datos histórica de 1233 eventos de voladura entre los años 2016 y 2020. Los resultados determinaron que el modelo para el P_{80} alcanzó un coeficiente R^2 de 0.9301 al incluir la variable de burden, identificando que la resistencia del macizo rocoso, el factor de potencia y los tiempos de retardo son las variables con mayor impacto estadístico. El estudio concluye que la implementación de modelos analíticos específicos permite mejorar la uniformidad del material enviado a planta y optimizar los costos de energía en el proceso de conminución.

2.3. ANTECEDENTES LOCALES

- Idrogo Y. (2022) en su tesis titulada "Machine Learning aplicado al control de la fragmentación de rocas en la voladura de minas a tajo abierto" para la Universidad Nacional de Ingeniería, desarrolla una metodología basada en el aprendizaje automático para predecir el P_{80} . Empleó un enfoque cuantitativo comparando algoritmos como Redes Neuronales, Random Forest y XGBoost utilizando una base de datos operativa de una unidad minera. Los resultados mostraron que el modelo Random Forest obtuvo el mejor desempeño con un coeficiente R^2 de 0.68 y una correlación de 0.82 en el conjunto de prueba, superando la precisión de los métodos empíricos tradicionales. El estudio concluye que la aplicación de estas técnicas permite identificar las variables con mayor impacto en la fragmentación, proporcionando una herramienta de predicción más confiable para optimizar los costos en los procesos posteriores de conminución.

3. PLANTEAMIENTO DE LA REALIDAD PROBLEMÁTICA

3.1. DESCRIPCIÓN DE LA REALIDAD PROBLEMÁTICA

Lograr una fragmentación de roca óptima no es una meta aislada; es, en realidad, el punto de partida que dicta la eficiencia energética de todo el proceso de conminución, desde el chancado hasta la molienda. En el marco de la Minería 4.0, la industria global está dejando atrás los métodos convencionales para adoptar analítica avanzada, entendiendo que cualquier desviación en el tamaño de partícula se traduce inmediatamente en un aumento de los costos operativos.

Si miramos hacia Chile o Brasil, vemos que sus principales unidades ya integran el aprendizaje automático para gestionar la variabilidad geomecánica de sus yacimientos. Es un paso lógico: la literatura técnica ha demostrado que los modelos empíricos tradicionales fallan ante macizos rocosos de estructuras complejas, obligando a las minas a operar bajo factores de seguridad que, en la práctica, resultan ineficientes.

En el Perú, el panorama es similar. Aunque nuestras unidades de gran escala cuentan con tecnología de monitoreo de punta, todavía persiste una dependencia crítica de fórmulas universales con décadas de antigüedad. Estos modelos no logran capturar la interacción no lineal de los parámetros de diseño local, generando cuellos de botella que comprometen la alimentación constante a la planta.

El caso de la unidad minera en el sur del país es un claro ejemplo de esta problemática. Aquí, la estabilidad del proceso productivo depende directamente de la fragmentación, pero su predictibilidad sigue anclada en modelos generales que ignoran las particularidades de la carga explosiva y el diseño de malla local. Las limitaciones del modelo Kuz-Ram son evidentes: no jerarquiza con precisión el peso estadístico de variables clave frente a la respuesta real del terreno.

Esta brecha entre la teoría y la práctica en campo se manifiesta en sobrecostos por fragmentación gruesa y un bajo rendimiento en el chancado primario. Por ello, aprovechando la robusta base de datos operativos de la unidad, se vuelve imperativo desarrollar un modelo de Machine Learning. El objetivo es claro: dejar de depender de estimaciones genéricas y establecer una expresión matemática propia, con coeficientes y exponentes locales que garanticen una optimización real y precisa del P_{80} .

3.2. FORMULACIÓN DEL PROBLEMA

3.2.1. PROBLEMA GENERAL

- ¿En qué medida el desarrollo de un modelo matemático basado en la jerarquización de variables por Machine Learning permite mejorar la precisión de las predicciones de fragmentación de roca en una unidad minera del sur?

3.2.2. PROBLEMA ESPECIFICO

- ¿Cuáles son las variables operativas de diseño y energía que presentan mayor peso estadístico en el comportamiento del P_{80} según el análisis de datos históricos mediante algoritmos de aprendizaje supervisado?
- ¿Cómo se define la estructura de una ecuación matemática (coeficientes y exponentes) que represente con mayor ajuste la interacción de las variables de voladura y la data real de fragmentación registrada?
- ¿Cuál es el nivel de reducción del error predictivo (RMSE) y mejora del coeficiente de determinación (R^2) del modelo matemático propuesto frente a los modelos empíricos tradicionales aplicados actualmente en la unidad?

4. OBJETIVO

4.1. OBJETIVO GENERAL

- Desarrollar un modelo matemático orientado a la predicción de la fragmentación de roca en una operación minera del sur, buscando elevar la exactitud de los pronósticos operativos mediante la aplicación de técnicas de Machine Learning.

4.2. OBJETIVOS ESPECÍFICOS

- Evaluar y clasificar el peso estadístico de los parámetros operativos (diseño de malla y energía) y los niveles de vibración registrados sobre el comportamiento granulométrico obtenido en el tajo.
- Definir la configuración de una ecuación matemática local, estableciendo coeficientes y exponentes que logren representar con mayor ajuste la interacción de las variables de voladura en el área de estudio.
- Contrastar el potencial predictivo del modelo propuesto frente a las ecuaciones convencionales, cuantificando la mejora real en los indicadores de precisión y ajuste estadístico (R^2 y $RMSE$).

5. HIPOTESIS

5.1. HIPÓTESIS GENERAL

Se plantea que la determinación de un modelo matemático a medida, fundamentado en la jerarquización de variables mediante Machine Learning, permitirá alcanzar estimaciones de fragmentación (P_{80}) con un grado de ajuste (R^2) superior y una desviación residual menor que los modelos universales aplicados en la unidad.

Variable dependiente: Precisión de la predicción de fragmentación (P_{80}).

Variable independiente: Modelo matemático específico basado en ML.

5.2. HIPÓTESIS ESPECIFICA

- El análisis de relevancia de variables a través de Machine Learning facilita la identificación de los factores de diseño, carga energética y vibraciones que ejercen una mayor influencia sobre los resultados de fragmentación local.

Variable dependiente: Identificación de factores con mayor influencia operativa.

Variable independiente: Jerarquización de importancia de variables mediante Machine Learning.

- Un modelo matemático cuyos componentes hayan sido calibrados específicamente para las condiciones de la mina presentará un nivel de correlación (R^2) más alto que el ofrecido por el estándar de Kuz-Ram.

Variable dependiente: Grado de ajuste estadístico R^2 .

Variable independiente: Estructura paramétrica del modelo local (coeficientes y exponentes).

- La implementación del modelo desarrollado bajo Machine Learning reducirá de manera significativa el error cuadrático medio (RMSE) en los pronósticos de fragmentación al compararlo con las fórmulas empíricas tradicionales de la operación.

Variable dependiente: Nivel de reducción del error predictivo (RMSE).

Variable independiente: Aplicación del modelo matemático específico.

6. MARCO TEÓRICO

6.1. BASES TEORICAS

6.1.1. Evolución del Modelado de Fragmentación de Roca

Dentro de la ingeniería de minas a cielo abierto, predecir la distribución del tamaño de fragmentos no es un detalle menor; constituye un pilar crítico para la viabilidad económica y la continuidad operativa. El impacto de una fragmentación óptima se extiende a lo largo de toda la cadena de valor, afectando directamente los indicadores de rendimiento en carguío, transporte y, fundamentalmente, en las etapas de trituración y molienda (Saldana et al., 2024; Toapanta-Delgado et al., 2025). En las últimas décadas, la industria ha experimentado una transición tecnológica notable, desplazándose de los modelos empíricos convencionales hacia arquitecturas de analítica avanzada e inteligencia artificial.

6.1.2. Modelos Empíricos Tradicionales: Kuz-Ram

Durante El modelo Kuz-Ram se ha mantenido como el estándar industrial para la estimación de fragmentación desde su introducción por Cunningham en 1983. Su estructura funcional combina la ecuación de energía de Kuznetsov —orientada a calcular el tamaño medio del fragmento (X_{50})— con la función de distribución de Rosin-Rammler para caracterizar la uniformidad de la granulometría (Mutinda et al., 2021). El cálculo depende estrictamente de variables de diseño (burden, espaciamiento, diámetro) y de las propiedades mecánicas del macizo, sintetizadas en el Factor de Roca (Saldana et al., 2024).

Sin embargo, la literatura técnica contemporánea ha puesto de relieve las limitaciones estructurales de Kuz-Ram. Su principal debilidad radica en la incapacidad de procesar relaciones no lineales complejas y la heterogeneidad inherente de los macizos rocosos, lo que deriva en una precisión predictiva reducida y una tendencia a sobreestimar el tamaño de los fragmentos (Lawal, 2021; Toapanta-Delgado et al., 2025). Asimismo, su deficiencia para modelar la generación de finos impulsó la aparición del modelo KCO (Kuznetsov-Cunningham-

Ouchterlony) en 2005. Este último sustituye la función Rosin-Rammler por la función Swebrec, logrando un ajuste superior en la curva de distribución de tamaños (Mutinda et al., 2021; Cunningham, 2005).

6.1.3. Integración Mine-to-Mill (M2M)

El paradigma Mine-to-Mill (M2M) propone una integración sistémica entre la caracterización del yacimiento, la voladura y el procesamiento posterior. La evidencia reciente sugiere que una fragmentación refinada desde la voladura no solo mejora el throughput del molino SAG, sino que reduce drásticamente el consumo específico de energía en la conminución (Saldana et al., 2024). Mediante estrategias M2M respaldadas por modelos predictivos, las operaciones pueden anticipar cuellos de botella y ajustar proactivamente la perforación para estabilizar la alimentación de la planta (Ramírez et al., 2025).

6.1.4. Predicción de Fragmentación mediante Inteligencia Artificial (IA)

Para superar el techo de precisión de los métodos empíricos, la minería moderna ha volcado sus esfuerzos hacia algoritmos de Machine Learning (ML), los cuales presentan una capacidad robusta para capturar la naturaleza no lineal de la fracturación de la roca.

6.1.5. Algoritmos Basados en Árboles de Decisión y Ensamble

El uso de arquitecturas como Random Forest (RF) y XGBoost ha sido validado en investigaciones recientes por su alta capacidad de generalización:

- **Random Forest (RF):** Este método de ensamble opera mediante la construcción de múltiples árboles de decisión. Diversos estudios comparativos demuestran que el RF supera a las ecuaciones tradicionales, logrando coeficientes de determinación R^2) por encima del 95 % en bases de datos globales (Toapanta-Delgado et al., 2025).
- **XGBoost (Extreme Gradient Boosting):** Es una técnica de refuerzo de gradiente que refina modelos secuencialmente para corregir errores previos. Se ha reportado que XGBoost, potenciado con optimización de

hiperparámetros (como ATPE), entrega una precisión superior en la predicción del X_{50} en comparación con los métodos de búsqueda aleatoria convencionales (Krop et al., 2024).).

6.1.6. Estrategias de Apilamiento (Stacking) y Aumento de Datos

Con el fin de maximizar el rendimiento predictivo, se han implementado estrategias de Stacking, que integran predicciones de modelos base (RF, SVM, XGBoost) a través de un meta-algoritmo. En estudios recientes, estos modelos alcanzaron un R^2 de 0.943 (Sui et al., 2025). Además, para mitigar la escasez de datos operativos, técnicas como SMOGN (Synthetic Minority Oversampling Technique for Regression with Gaussian Noise) han demostrado ser eficaces para mejorar la robustez del modelo (Krop et al., 2024).

6.2. MARCO CONCEPTUAL

6.2.1. Variables de Fragmentación y Diseño

- **P_{80} (X_{80}):** Define el tamaño de malla por el cual atraviesa el 80 % del material. Es el indicador maestro para medir la eficiencia de la voladura y su impacto en el chancado (Saldana et al., 2024; Ramírez et al., 2025).
- **Tamaño Medio de Fragmento (X_{50}):** Corresponde al tamaño de partícula para el 50 % pasante en la curva granulométrica. Actúa como la variable dependiente central en modelos de IA y ecuaciones de Kuznetsov (Sui et al., 2025).
- **Factor de Carga (Powder Factor - PF):** Cantidad Relación de masa de explosivo por unidad de volumen de roca (kg/m^3). Los análisis de importancia de variables lo señalan como uno de los parámetros con mayor peso en la predicción de fragmentación (Toapanta-Delgado et al., 2025).

- **Burden (B) y Espaciamiento (S):** Pilares geométricos de la malla de perforación; el burden mide la distancia a la cara libre y el espaciamiento la separación entre taladros de una misma fila (Toapanta-Delgado et al., 2025).

6.2.2. Algoritmos y Técnicas de Modelado

- **Modelo Kuz-Ram:** Marco empírico que fusiona la ecuación de Kuznetsov y la función Rosin-Rammler para estimar la fragmentación mediante energía y geomecánica (Lawal, 2021).
- **Random Forest (RF):** Algoritmo supervisado que promedia los resultados de un bosque de árboles de decisión para minimizar el sobreajuste (Sui et al., 2025)
- **XGBoost:** Algoritmo de Gradient Boosting optimizado para velocidad y regularización, diseñado para prevenir el ruido en los datos (Krop et al., 2024).
- **Clustering (Agrupamiento):** Método no supervisado (ej. K-means) que segmenta datos heterogéneos en grupos con características similares antes del entrenamiento (Krop et al., 2024).

6.2.3. Métricas de Evaluación de Modelos

- **Coeficiente de Determinación (R^2):** Indica qué porcentaje de la varianza de la fragmentación es explicado por el modelo. Valores próximos a 1 reflejan un ajuste óptimo (Sui et al., 2025).
- **Error Cuadrático Medio (MSE - Mean Squared Error):** Promedio de los errores al cuadrado; su minimización es el objetivo central en el entrenamiento de redes y árboles (Toapanta-Delgado et al., 2025).
- **Error Absoluto Medio (MAE - Mean Absolute Error):** Expresa la diferencia promedio absoluta entre el valor real y el predicho, ofreciendo una lectura lineal de la precisión (Ramírez et al., 2025).

7. CRONOGRAMA DEL TRABAJO

		AÑO 2026															
		FEBRERO				MARZO				ABRIL				MAYO			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
I.	RECOLECCIÓN DE DATOS																
1.1	Recolección de información del Proyecto																
1.2	Recolección de información de mediciones en campo																
1.3	Realización de encuestas																
II.	PROCESAMIENTO DE LA INFORMACIÓN																
2.1	Digitalización y procesamiento de información																
2.2	Aplicación de metodología de investigación																
III.	ANÁLISIS DE LA INFORMACIÓN																
3.2	Validez de investigación																
3.3	Contratación de la hipótesis																
3.4	Conclusión y Recomendaciones																

8. BIBLIOGRAFIA

- Chandrahas, N. S., Choudhary, B. S., Teja, M. V., Venkataramayya, M. S., & Prasad, N. S. R. K. (2022). XG Boost algorithm to simultaneous prediction of rock fragmentation and induced ground vibration using unique blast data. *Applied Sciences*, 12(10), 5269. <https://doi.org/10.3390/app12105269>
- Idrogo Zamora, Y. P. (2022). Machine Learning aplicado al control de la fragmentación de rocas en la voladura de minas a tajo abierto [Tesis de título profesional, Universidad Nacional de Ingeniería]. Repositorio Institucional UNI.
- Ohadi, B., Sun, X., Esmaili, K., & Consens, M. P. (2019). Predicting blast-induced outcomes using random forest models of multi-year blasting data from an open pit mine. *Bulletin of Engineering Geology and the Environment*, 78, 6245-6257. <https://doi.org/10.1007/s10064-019-01566-3>
- Ramírez Oscoco, R., Sagastegui Ayala, F. E., & Mansilla Olivas, J. M. (2025). Predicción de fragmentación de roca mediante Machine Learning en voladuras de minería a tajo abierto [Ponencia]. PERUMIN 37 Convención Minera, Arequipa, Perú.
- Sui, Y., Zhou, Z., Zhao, R., Yang, Z., & Zou, Y. (2025). Open-Pit Bench Blasting Fragmentation Prediction Based on Stacking Integrated Strategy. *Applied Sciences*, 15, 1254. <https://doi.org/10.3390/app15031254>
- Vargas Flores, N. N., & Marcelo Encarnación, M. A. (2024). Optimización de la voladura en una mina superficial a través de un modelo predictivo para determinar el nivel de fragmentación aplicando Machine Learning [Tesis de título profesional, Pontificia Universidad Católica del Perú]. Repositorio Institucional PUCP.
- Cunningham, C. V. B. (2005). The Kuz-Ram fragmentation model – 20 years on. *Proceedings of the 3rd European Federation of Explosives Engineers World Conference on Explosives and Blasting*, 201–210.
- Krop, I., Sasaoka, T., Shimada, H., & Hamanaka, A. (2024). Optimizing Mean Fragment Size Prediction in Rock Blasting: A Synergistic Approach Combining

Clustering, Hyperparameter Tuning, and Data Augmentation. *Engineering*, 5(3), 1905–1936. <https://doi.org/10.3390/eng5030102>

- Lawal, A. I. (2021). A new modification to the Kuz-Ram model using the fragment size predicted by image analysis. *International Journal of Rock Mechanics and Mining Sciences*, 138. <https://doi.org/10.1016/j.ijrmms.2020.104595>
- Mutinda, E. K., Alunda, B. O., Maina, D. K., & Kasomo, R. M. (2021). Prediction of rock fragmentation using the Kuznetsov-Cunningham-Ouchterlony model. *Journal of the Southern African Institute of Mining and Metallurgy*, 121(3), 107–112. <http://dx.doi.org/10.17159/2411-9717/1401/2021>
- Ramírez, R., Sagastegui, F., & Mansilla, J. (2025). Predicción de Fragmentación de Roca mediante Machine Learning en Voladuras de Minería a Tajo Abierto (Optimización de procesos en Minería con Analítica Avanzada – Minería 4.0). Trabajo Técnico 650. Astay Systems.
- Saldana, M., Gallegos, S., Arias, D., Salazar, I., Castillo, J., Salinas-Rodríguez, E., Navarra, A., Toro, N., & Cisternas, L. A. (2024). Applications of Kuz–Ram Models in Mine-to-Mill Integration and Optimization—A Review. *Minerals*, 14(11), 1162. <https://doi.org/10.3390/min14111162>
- Toapanta-Delgado, S., Guerrero-Rodriguez, B., & Mejia-Escobar, C. (2025). Fragmentación de Roca por Voladura en Minería a Cielo Abierto: Predicción con IA. *Revista Tecnológica - Espol*, 37(E1), 38–54. <https://doi.org/10.37815/rte.v37nE1.1356>
- Yilmaz, O. (2024). An Alternative Approach to Burden Estimation Based on Targeted Mean Fragment Size Using Rock Fragmentation Models. *Karaelmas Science and Engineering Journal*. <https://doi.org/10.7212/karaelmasfen.1457424>